Arquitetura de dados para acompanhamento do CNCA

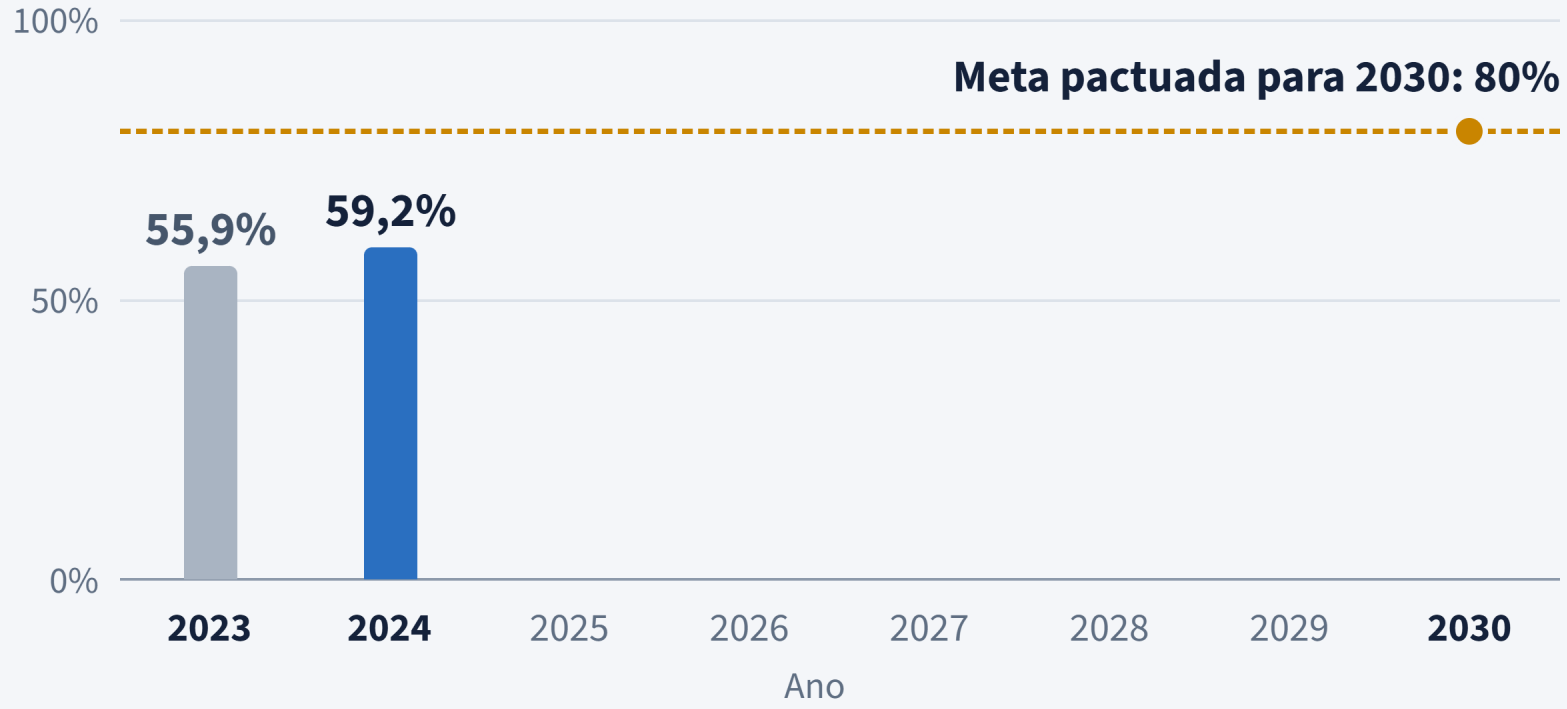
Um fluxo de dados híbrido e confiável para acompanhar o Compromisso Nacional Criança Alfabetizada (CNCA), município a município

Tech Challenge, Fase 2

Fagner Carvalho Tonon · Beatriz Marciliano Sant Anna · Gustavo Mendes de Oliveira · Vanessa Silva Menezes · Júlio Wehba Bruna

Objetivo: um fluxo de dados confiável para acompanhar a meta de 80% até 2030

% de alunos da rede pública alfabetizados ao fim do 2º ano



Quem conta como alfabetizado

743 pontos ou mais na avaliação nacional (Saeb)

Meta e aspiração

Apesar da meta de 80%, aspiramos a 100%.

Fonte: Inep via Base dos Dados. README §1 e §6

Seis bases públicas: cada resultado precisa achar a meta do mesmo lugar, ano e rede



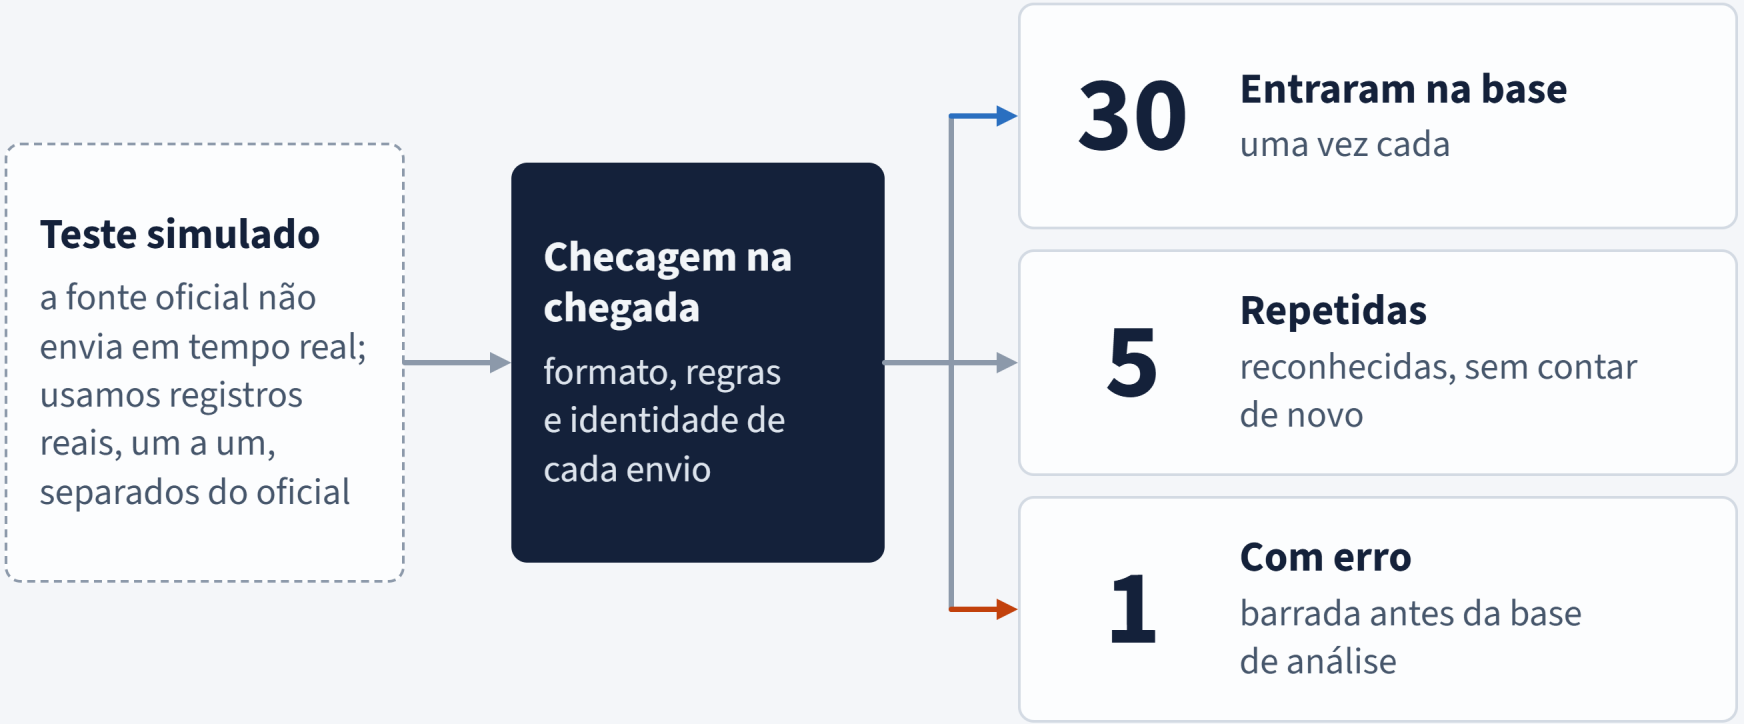
Arquitetura medalhão: do dado bruto à análise



Arquitetura escalável: só consome recursos quando roda.

Fonte: README §2, §3 e §5. Execução na nuvem AWS

Correções e dados novos entram em fração de segundo, sem esperar a carga anual



0,181 s

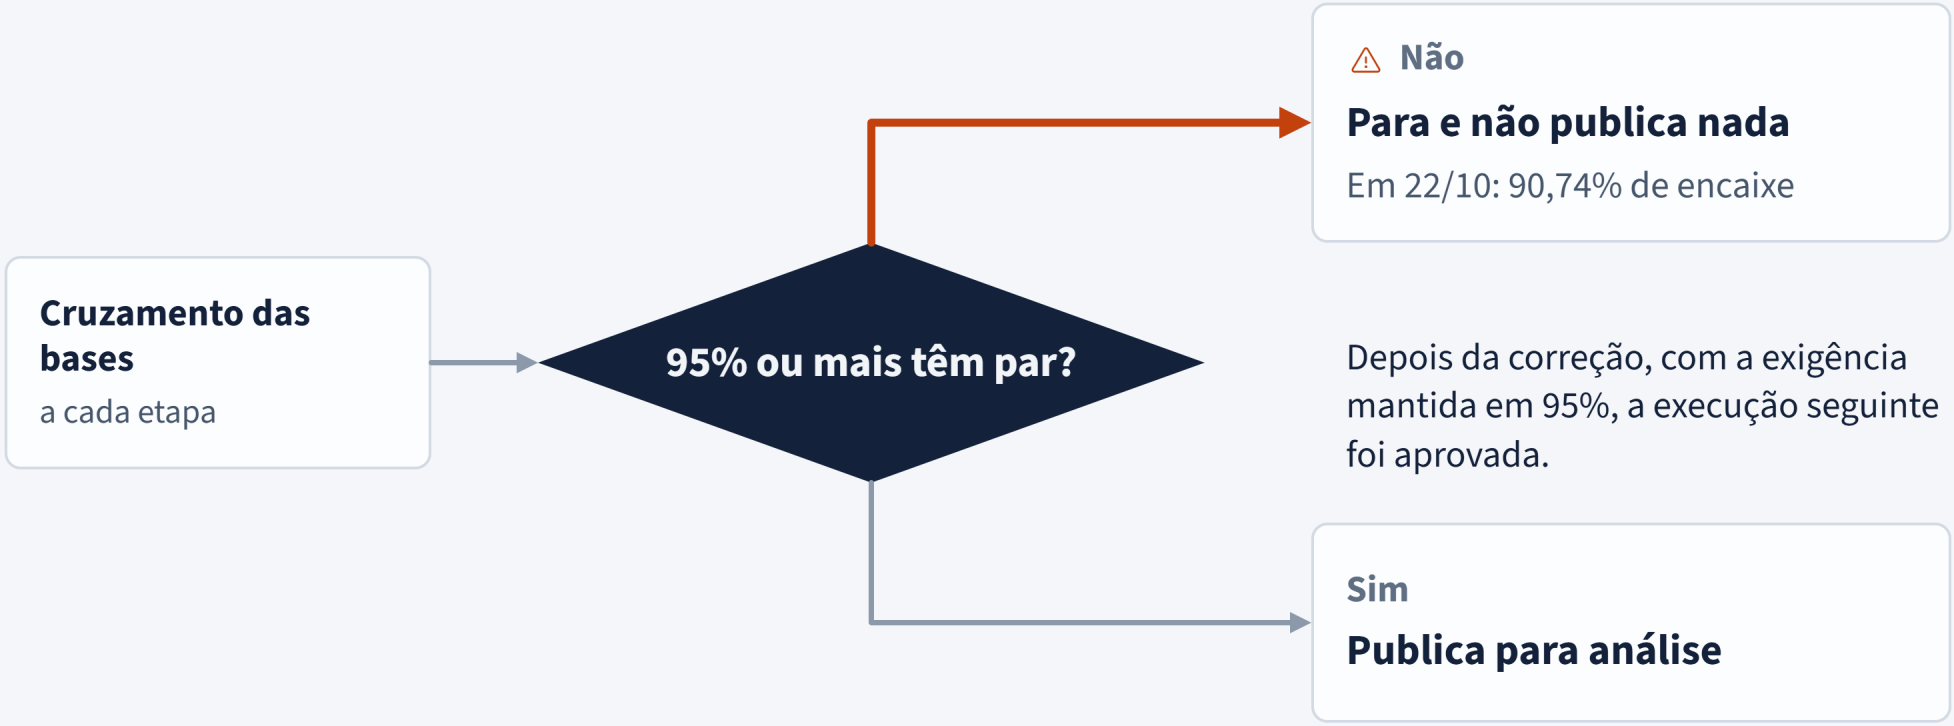
mediana, do envio até a base de análise

Carga anual completa

minutos

Fonte: README §4 e §7

Se as bases não se encaixam, o sistema não publica nada



Prova final: recalculado a partir de cada aluno, o indicador de 2024 bate com o do Inep.

Fonte: README §6. Indicador de 2024 recalculado: 59,1996% contra 59,2% oficial

O alarme detectou a falha em 1 min 54 s; hoje, ele também avisa a equipe por e-mail

22 de outubro, horário UTC

14:06:02
Falha registrada

14:07:56
Alarme dispara no painel

1 min 54 s

Cada execução registra quanto tempo levou, quanto processou e se deu certo. Todo número pode ser rastreado até a execução que o gerou.

A partir de 27/10: aviso por e-mail

Alerta: falha no processamento de dados

Uma regra de qualidade barrou a publicação. Verifique a execução.

✓ **Teste de 27/10: e-mail recebido**

ilustração

Fonte: README §7

Operar o fluxo custa US$ 2,15 a cada 30 dias; dois custos ainda não foram medidos

US$ 2,15

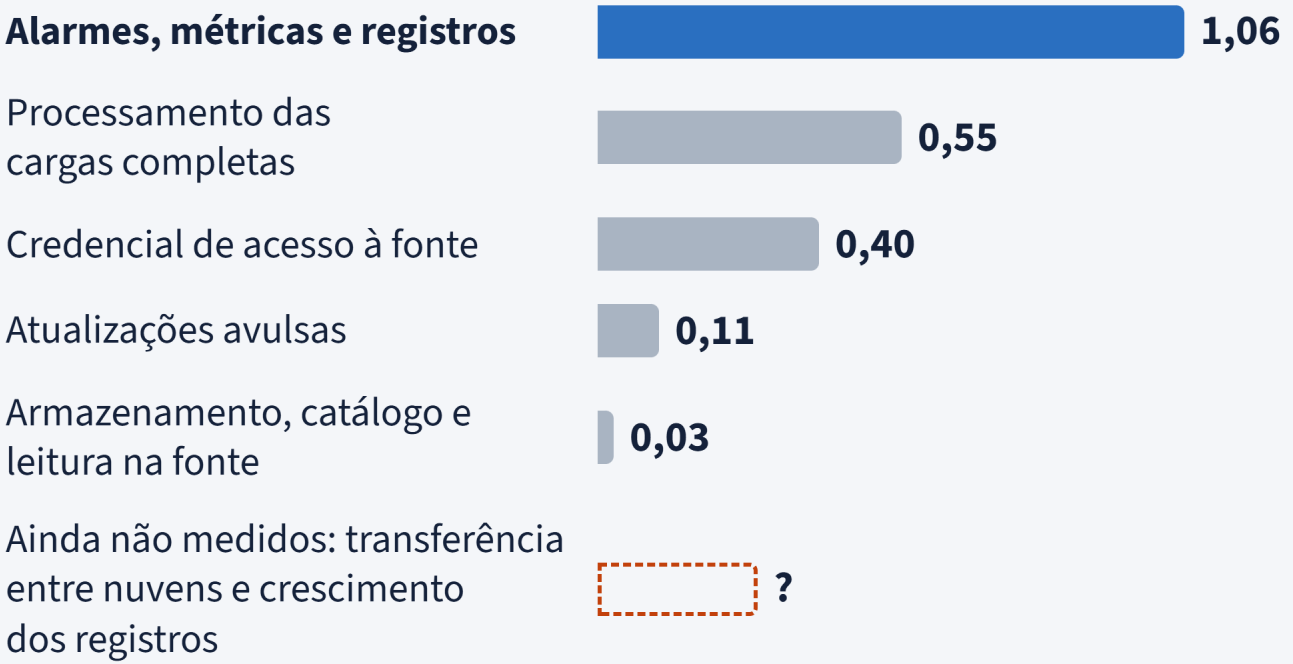
a cada 30 dias, pelo consumo medido

Rotina assumida: 4 cargas completas e 4 rodadas de atualizações por mês.

Já otimizado: arquivos compactados, só 2 máquinas por etapa e tempo-limite em cada execução.

⚠ **Atenção: a transferência entre nuvens e o crescimento dos registros ainda não foram medidos e podem elevar esse valor.**

De onde vem o custo, em US$ a cada 30 dias



Fonte: README §8. Cada categoria soma parcelas da tabela de custos

O valor do fluxo: bases prontas para as perguntas da gestão

Quem atingiu a meta do ano?

10.948

linhas de resultado e meta, por município, estado e Brasil

Cada caso classificado: atingiu, não atingiu, sem meta ou sem resultado.

Quanto falta para 2030?

80%

meta pactuada, usada como régua

Distância, em pontos, entre o resultado de cada município, estado e do Brasil e a meta de 2030.

Estamos avançando?

52

linhas de evolução por estado e Brasil

Variação de um ano para o outro, pronta para painel.

Tudo pronto para virar painel ou análise estatística, sem retrabalho.

Fonte: README §1 e §5. Tabelas da camada Gold

A base já está pronta para treinar um modelo preditivo

O que o modelo recebe

11.345

combinações de município, série e rede, com dados de 2023:

- taxa de alfabetização
- proficiência em português
- alunos avaliados

O que ele aprende

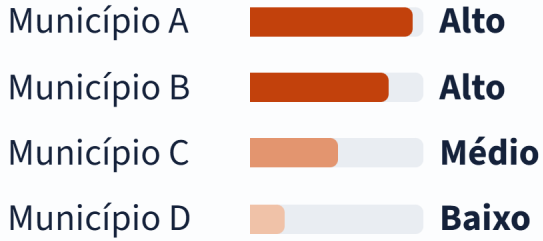
Como o resultado de um ano antecipa o do ano seguinte

2023 → 2024

Nada de 2024 entra como pista (data leakage)

O que a Fase 3 pode entregar

Municípios ordenados pelo risco de não atingir a meta

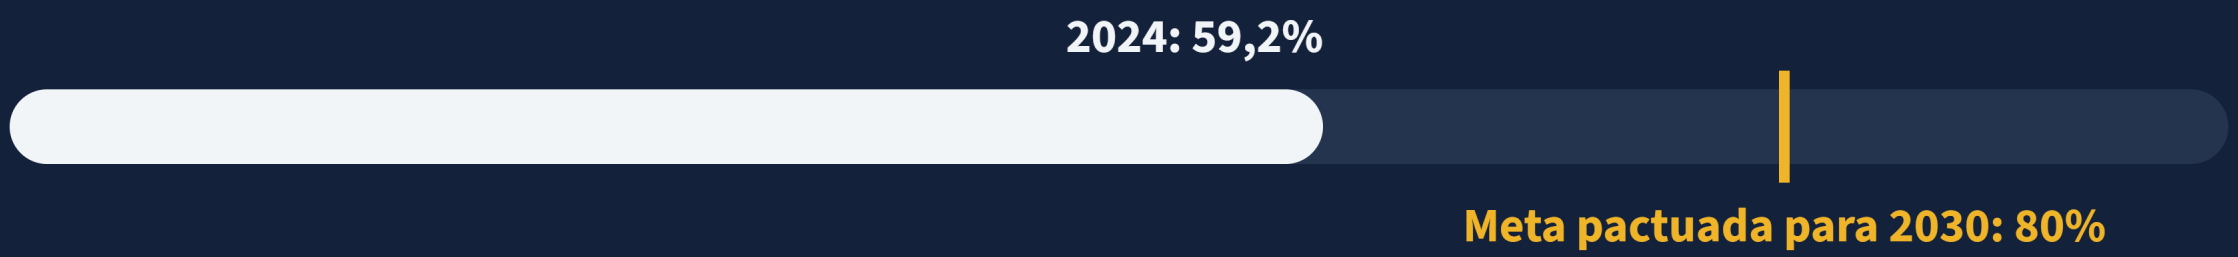


Ilustração, sem dados reais

Fonte: README §10. Base de treino preservada na camada Gold

Onde agir para chegar a 80%?

Agora dá para responder município a município.



Dados que batem com os números oficiais, mesmo se houverem atualizações em tempo real.

Próximo passo: treinamento do modelo, na Fase 3

github.com/fagnertonon/POS-TECH-CIENCIA-DE-DADOS · rodou na AWS · 140 testes automáticos · evidência de cada execução no repositório