Gold atualizada e validada na AWS

A versão 1.0.2 acrescenta cobertura geográfica e notas da fonte à validação nacional. O job final terminou SUCCEEDED, publicou um novo manifesto e preservou o histórico anterior.

A origem continua sendo o BigQuery da Base dos Dados. A atualização reutilizou a Silver aprovada de 22/10/2026; não repetiu a Bronze nem consultou novamente o BigQuery.

Verificação	Resultado comprovado
Publicação	Cinco datasets Gold, todos com contagens e schemas Parquet conferidos por observador independente.
Regressão	Contagens das cinco tabelas iguais às anteriores; os oito campos antigos das duas linhas nacionais também iguais.
Testes	24 testes locais aprovados. Fixture Spark: 6 regras bloqueantes e 4 registros informativos, todos aprovados.
Execução final	174 segundos; 349 DPU-segundos informados pela API; 2 workers G.1X, zero retentativas, timeout de 15 minutos.

Dataset Gold	Linhas
indicador_municipio	23.995
resultado_vs_meta	10.948
evolucao_temporal	52
validacao_cruzada_brasil	2
features_alfabetizacao	11.345
Total	46.342

Por que validar uma fonte do BigQuery?

BigQuery oferece acesso e estrutura. A Silver já padroniza tipos e chaves, verifica duplicidades, traduz códigos e valida pesos/flags. Isso não acrescenta observações ausentes da publicação nem torna todas as tabelas estatisticamente equivalentes. A nova Gold torna essas diferenças rastreáveis.

O enunciado da Fase 2 aceita BigQuery (p.4), exige tratamento e validação (pp.6-7) e valoriza investigação documentada de anomalias (p.13). Os CSVs originais do Inep foram usados para auditoria; a linhagem do pipeline permanece BigQuery -> Bronze -> Silver -> Gold.

O que muda na interpretação dos números

Ano	Recalculada	Oficial	Diferença	UFs nos alunos
2023	57,4622%	55,9%	+1,5622 p.p.	23
2024	59,1996%	59,2%	-0,0004 p.p.	26

2023 continua fora da tolerância de 0,1 p.p. Há microdados elegíveis de 23 UFs, sem AC, DF, RR e SP. O resultado agregado de SP existe em uf. O Leia-Me oficial de 2023 documenta, na p.17, a publicação de TS_ALUNO sem São Paulo. Não foi demonstrado que apenas SP explica toda a diferença nacional.

2024 permanece dentro da tolerância numérica. Há 26 UFs nos alunos e ausência de RR. DF tem microdados, mas não resultado em uf/TS_ESTADO; o Leia-Me de 2024 documenta essa situação nas pp.21-22. A concordância numérica não comprova identidade de metodologia.

Novos campos da validação nacional

Campo	Significado
quantidade_ufs_microdados	Número de UFs distintas dos alunos incluídos no denominador público.
ufs_microdados / ufs_sem_microdados	Presenças e complemento das 27 UFs; referência geográfica, sem estimar participação de alunos.
ufs_resultados_uf	UFs com resultado não nulo na mesma série, ano e rede pública.
ufs_resultados_sem_microdados	UFs dos resultados ausentes nos alunos; SP em 2023.
ufs_microdados_sem_resultado_uf	UFs dos alunos ausentes nos resultados UF; DF em 2024.
status_comparabilidade / nota_fonte	Comparação dos conjuntos e limites de interpretação, independentes de dentro_tolerancia.

Neste snapshot, os dois anos recebem COBERTURA_DIFERENTE_ENTRE_BASES porque alunos e resultados UF têm conjuntos diferentes. A tabela uf não é usada como definição completa do universo do indicador Brasil. Se os conjuntos coincidirem no futuro, o status ainda informa que a equivalência metodológica não está comprovada.

Também permanecem documentadas as diferenças de MS (+0,3149 p.p.) e SE (-0,2619 p.p.) em 2023, reproduzidas diretamente da fonte. Não houve substituição de valores para obter concordância.

Como foi implementado e comprovado

A função resumir_cobertura_brasil classifica conjuntos de UFs. A etapa Spark usa os alunos avaliados das redes 2+3 e infere a UF pelo prefixo IBGE do município normalizado. Um prefixo desconhecido bloqueia a execução. Alunos ausentes e privados não entram na cobertura pública.

O enriquecimento usa ano, série e rede, com correspondência medida. Após gravar e reler o Parquet, a Gold verifica presença dos metadados, domínio dos status e consistência dos conjuntos. As evidências ficam no manifesto e nos arquivos de qualidade.

Preservações verificadas

A fórmula ponderada, os filtros de avaliados, o limiar de joins de 95% e a tolerância de 0,1 p.p. foram mantidos. A comparação local por AST confirmou que as funções dos indicadores, metas, evolução e features preservam a lógica anterior. O notebook adaptado corresponde ao script implantado.

A conferência posterior verificou as contagens das cinco tabelas e a igualdade dos oito campos nacionais anteriores. Isso não representa uma comparação de todos os valores, linha a linha, das cinco tabelas.

Teste Spark e primeira tentativa

A fixture opcional VERIFY_COVERAGE_FIXTURE executa dados pequenos e sintéticos para testar cálculo, cardinalidade, exclusão de privados/ausentes, prefixo inválido e as novas regras de metadados. As métricas sintéticas ficam separadas; a fixture não grava dados analíticos na Gold.

A primeira tentativa falhou em 148 segundos por uma chamada Column.isin com tuple incompatível com o runtime Spark. A correção usa list e passou a exercitar as regras extras na fixture. A tentativa falha tem published=false e nenhum manifesto aprovado; deixou arquivos staged, que não devem ser consumidos. A execução final concluiu em 174 segundos.

Controle de custo desta atualização

Tentativa	DPU-segundos	Glue estimado
Primeira - FAILED	296	US$ 0,03618
Final - SUCCEEDED	349	US$ 0,04266
Total da atualização	645	US$ 0,07883 (aprox. US$ 0,08)

Modelo: 645 / 3.600 x US$ 0,44 por DPU-hora. A tarifa de Ohio foi consultada na AWS Price List em 26/10/2026. São valores brutos apenas do processamento Glue, antes de créditos; não representam a fatura completa ou o saldo disponível. Foi reutilizado o job existente, com novos assets e tabelas versionadas; sem ampliação de IAM ou criação de agendas.

Comandos, rastreabilidade e estudo

Comandos para reprodução no CloudShell

Execute a partir da raiz do pacote extraído, onde estão gold/ e verify_continuacao.py. A execução já foi concluída; repetir a publicação abaixo é opcional e requer uma pasta de evidências nova.

```
python3 -m unittest discover -s gold -p "test_gold_*.py" -q

SHA_ANTERIOR=43ff8eb000efd0c946629f7683ce2fd9f712a829e40077c58c20702ed6912ae8
python3 gold/publicar_gold_cobertura.py \
  --directory gold --output-dir deploy_nova_execucao \
  --expected-previous-sha256 "$SHA_ANTERIOR" --run
```

O publicador confirma conta, tags, capacidade e ausência de execução ativa, preserva a configuração anterior e envia assets por SHA-256. Uma nova chamada bem-sucedida com --run inicia outra execução e gera cobrança. Diretórios de evidência existentes são recusados para preservar o histórico.

```
RUN=jr_2f49f1ef178c48d81fd1f61569da095c16d1e58d8f7a15ce11ae9c4f6b84cc29
python verify_continuacao.py --layer gold --run-id "$RUN" \
  --verify-parquet --output verificacao_gold.json
```

O verificador usa boto3/PyArrow, lê manifestos e footers e não inicia Spark. O pacote também inclui verificar_cobertura_final.py com a conferência desta execução e comparação dos campos nacionais. Esse script registra caminhos do CloudShell usado nesta auditoria; ajuste a pasta de trabalho se reproduzir em outro ambiente.

Identificadores da publicação

```
Job: fiap-gold-inep-batch | Regiao: us-east-2
Run final:
jr_2f49f1ef178c48d81fd1f61569da095c16d1e58d8f7a15ce11ae9c4f6b84cc29
SHA-256 do script:
a36f8f94b15a574c0c8d79631c00b7dd016526437ef5d55645df83b1249e0d7e
```

Manifesto final no S3:

```
s3://fiap-tc-fase2-2026/auditoria/gold/
ingestion_date=2026-10-26/run_id=
jr_2f49f1ef178c48d81fd1f61569da095c16d1e58d8f7a15ce11ae9c4f6b84cc29/manifest.json
```

Na URI acima, remova as quebras de linha usadas apenas para leitura. Consumidores devem selecionar os caminhos do manifesto SUCCEEDED. O pacote contém manifestos anterior/final, configuração antes da mudança, registros das duas tentativas, verificações, códigos, hashes e documentos de apoio.

Referências para estudo

Enunciado: POSTECH - IAST - Tech Challenge - Fase 2, pp.4, 6, 7 e 13. Inep: Leia-Me AEEB 2023, p.17; Leia-Me AEEB 2024, pp.21-22. Documentos extraídos dos ZIPs oficiais e preservados junto ao diagnóstico. Consulta técnica: spark.apache.org/docs/3.5.6/api/python/_modules/pyspark/sql/column.html. Tarifas: aws.amazon.com/glue/pricing/ e AWS Price List regional registrada nas evidências.

A atualização de cobertura está concluída. A entrega geral ainda deve reunir repositório reproduzível, README/arquitetura, FinOps consolidado e o vídeo executivo previsto no desafio.