Streaming até a Gold de simulação

Tech Challenge Fase 2 | FIAP | Histórico técnico e guia de estudo

A extensão levou uma nova rodada de eventos simulados da SQS até contribuições analíticas Gold e consolidou o conjunto validado em Parquet Snappy. Os relatórios de produtor, verificação positiva, snapshot, falha controlada e inventários oficiais terminaram com SUCCEEDED. A publicação da stack terminou com UPDATE_COMPLETE.

Resultado medido	Quantidade
Eventos válidos distintos	30
Reenvios idênticos de teste	5
Evento semântico inválido, em rodada separada	1
Bronze / Silver / contribuições Gold / recibos	30 / 30 / 30 / 30
Silver compactada	30 linhas
Gold por ano, UF, série e rede	19 grupos
Testes locais comprovados	88
Inventários oficiais comparados antes/depois	6 iguais

Escopo e orçamento

Orçamento total do projeto: US$ 140. Esta entrega registra controles de recursos e quantidades observadas; não calcula faturamento ou saldo disponível. O fechamento FinOps e a projeção de custos ficam para a demanda seguinte. A rodada não iniciou consultas BigQuery, jobs Glue nem agendamentos.

Origem de todas as saídas derivadas: SIMULAÇÃO (origin=simulacao_replay_inep, simulation=true). A amostra de replay não representa o indicador nacional e não deve ser apresentada como uma nova medição oficial do Inep.

Identificação da evidência

```
Conta AWS: 637246457028
Região: us-east-2 (Ohio)
Bucket: fiap-tc-fase2-2026
Run: sim_gold_20261027T155422Z_a52da0a7
Snapshot: 364dc24b2ba6e750ef0103b8138a9750c9bb24e081b325234a42a509cd717c2b
Versão da transformação: 2.0.0
```

O que mudou e por que funciona

Etapa	Comportamento implementado
Produtor	Lê uma amostra já existente no S3 e emite 30 eventos em intervalos de 1 s; depois reenvia os mesmos 5 eventos, preservando IDs e bytes.
SQS Standard	Entrega pelo menos uma vez e sem ordem garantida. Falhas individuais retornam em batchItemFailures; o redrive leva a mensagem à DLQ após o limite configurado.
Bronze e claim	Preservam o envelope bruto e a primeira recepção. PUT condicional impede sobrescrita; identidade=(run_id,event_id).
Silver incremental	Valida chaves, domínio, avaliação, alfabetização e peso; identifica a UF pelo código IBGE do município. Grava JSON gzip por evento.
Gold incremental	Grava contribuições aditivas de contagem e pesos por evento. Não existe contador cumulativo compartilhado sujeito a perda de atualização.
Recibo GOLD_READY	É persistido após o PUT Gold, com hashes, caminhos, instante de conclusão e latência real. Um claim isolado não comprova conclusão.
Finalizador	Lê apenas os IDs esperados, valida as projeções e recibos, compacta Silver/Gold em Parquet Snappy e publica o manifesto por último.

Idempotência e recuperação

Dois consumidores podem trabalhar simultaneamente. Cada evento tem chaves imutáveis próprias e escritas condicionais. Se a Bronze existir e uma etapa seguinte tiver falhado, o retry completa a projeção; ele não confirma prematuramente o evento como duplicata. Mesmo ID com outro envelope ou conteúdo derivado falha. O efeito no S3 é idempotente, sem afirmar entrega exatamente uma vez pela SQS.

Os arquivos Parquet representam um snapshot fechado. Repetir o finalizador com os mesmos IDs, hashes e versão encontra o mesmo snapshot. A presença de arquivos sem manifesto não autoriza leitura de uma conclusão parcial.

Publicação e fidelidade do código

O change set foi revisado e a atualização foi limitada à função e à role existentes. Antes do primeiro envio, o exercício conferiu os bytes do ZIP Lambda instalado contra o código local testado. A exportação GetTemplate pode substituir comentários não ASCII por '?'; a tolerância cobre somente essa conversão observada. A comparação do código real instalado continua exata em UTF-8.

```
SHA-256 do código Lambda validado:
a41f53b8ac337c198fb0c8ad955eeb35184bbf1857ffca3a02c9a998b39a9ee7
```

Qualidade, falha controlada e latência

Avaliado = presente E caderno_preenchido. Somente avaliados entram no denominador. Alfabetização conhecida e peso positivo finito são obrigatórios para um avaliado; proficiência não define elegibilidade. Ausência de resultado não é convertida silenciosamente em falso.

Teste negativo medido	Resultado
Entrada	Peso zero para aluno avaliado, em run isolado
Bronze / claim / auditoria	Preservados; status QUALITY_REJECTED
Silver / Gold / recibo GOLD_READY	0 / 0 / 0 objetos
Falhas InvalidPayload observadas nos logs	5
DLQ	Mensagem encontrada com o mesmo hash e ID
Mensagens apagadas / redriven pelo verificador	0 / 0

A inspeção da DLQ devolve a visibilidade das mensagens lidas. Seu contador ApproximateReceiveCount também pode aumentar com a inspeção; ele não é uma contagem exata das tentativas originais da Lambda. Os logs do message_id documentam as rejeições de processamento.

Latência real até a contribuição Gold

Métrica	Valor
Amostras	30
Mínima	0,155 s
Mediana	0,181 s
Média	1,173 s
P95 (nearest rank)	5,997 s
Máxima	8,045 s

Medição: completed_at_utc do consumidor, obtido depois do PUT Gold, menos event_time emitido pelo produtor. A verificação recalcula a diferença a partir dos dois carimbos independentes. O recibo é persistido depois da medição. Esses números não representam a duração da compactação Parquet, nem devem ser misturados à antiga medição somente até Bronze.

```
Run negativo: invalid_weight_489d809c1c474853
SQS message_id: 5dcca064-4ab7-4b09-9f17-706f96d96e8d
```

Medições operacionais e auditoria durável

Medição observada	Resultado
Registros de processamento válidos / duplicados / inválidos	30 / 5 / 5
Invocações correlacionadas com linha REPORT	39
Soma Duration dos REPORTs	17,334 s
Soma Billed Duration dos REPORTs	17,627 s
Maior Max Memory Used observado	93 MB
Arquivos de evidência publicados e relidos por hash	14

Os totais de REPORT incluem apenas invocações correlacionadas a registros alvo, sem eventos alheios identificados na mesma invocação. Quantidade de eventos, recebimentos e invocações são medidas diferentes: uma invocação pode processar um lote. Métricas globais de CloudWatch e os contadores de fila têm escopo compartilhado e janela de tempo; não são atribuídos automaticamente a esta rodada.

Billed Duration é uma quantidade medida nos logs, não um preço ou fechamento de cobrança. Não foi aplicada tarifa, desconto, crédito ou projeção mensal neste relatório. Essas informações serão reconciliadas na próxima demanda de FinOps.

Monitoramento na captura

Alarme existente	Estado observado
fiap-inep-streaming-age	OK
fiap-inep-streaming-dlq	ALARM
fiap-inep-streaming-rejected	ALARM

Os alarmes têm períodos de 60 s e ficam visíveis no console. Não há destinatário em AlarmActions nesta captura, portanto não se afirma envio de e-mail. O responsável acompanha o console e os verificadores durante a execução manual. O estado ALARM da DLQ também inclui a evidência antiga preservada; a nova mensagem foi identificada separadamente pelo message_id e hash.

Auditoria final no S3

```
s3://fiap-tc-fase2-2026/auditoria/streaming/runs/run_id=sim_gold_20261027T155422Z_a52da0a7/manifest.json
```

O manifesto final de auditoria referencia 14 evidências. O processo releu os objetos publicados e conferiu seus hashes de conteúdo; o resultado de readback foi SUCCEEDED. Esse manifesto é distinto do manifesto analítico que aponta os dois arquivos Parquet do snapshot.

Gold de simulação: como analisar

Granularidade: run + ano educacional + UF + série + rede. A rede permanece elementar (1 federal, 2 estadual, 3 municipal, 4 privada); não há mistura com resultados oficiais nem aplicação de metas oficiais neste dataset.

```
taxa (%) = 100 * SUM(soma_peso_alfabetizados)
 / SUM(soma_peso_avaliados)

Denominador zero -> taxa ausente (null).
Não usar média simples das taxas dos grupos.
```

Ano	UF	Série	Rede	Eventos	Avaliados	Taxa (%)
2023	AM	2	3	2	0	ausente
2023	CE	2	3	1	1	100,0000
2023	MG	2	3	4	4	23,6038
2023	MT	2	3	1	1	0,0000
2023	PA	2	3	2	0	ausente
2023	PI	2	3	1	1	0,0000
2023	RJ	2	3	1	0	ausente
2023	RN	2	3	1	1	0,0000
2024	AC	2	2	1	1	0,0000
2024	AM	2	3	1	1	100,0000
2024	BA	2	3	1	0	ausente
2024	CE	2	3	2	2	100,0000
2024	ES	2	3	2	2	47,2973
2024	MT	2	3	1	1	0,0000
2024	PR	2	3	1	1	100,0000
2024	RJ	2	3	2	2	46,1538
2024	RS	2	3	1	1	100,0000
2024	SC	2	2	1	1	100,0000
2024	SP	2	3	4	3	66,6667

Cada linha e cada arquivo mantêm a origem SIMULAÇÃO e a identificação da execução. As contagens descrevem apenas os eventos de demonstração; a taxa de uma amostra tão pequena não deve fundamentar uma conclusão sobre a população de uma UF.

Preservação do histórico oficial

Foram comparados seis inventários completos antes e depois. Em cada prefixo permaneceram iguais a quantidade de objetos, o total de bytes e o SHA-256 do inventário ordenado. Esse hash resume chave, tamanho, ETag e última modificação; não é uma nova leitura integral de cada arquivo oficial.

Prefixo oficial	Objetos antes/depois	Bytes antes/depois
bronze/inep/	55	186744593
silver/inep/	10	61906268
gold/inep/	103	8029402
auditoria/bronze/	12	46195
auditoria/silver/	10	447666
auditoria/gold/	45	352568

bronze/inep/

```
SHA-256 igual antes/depois:
8a47059fbb2617182f13875166cc8d632ee884a09d9912a9a76c73c6dcb28bea
```

silver/inep/

```
SHA-256 igual antes/depois:
2ceb712953555c5d84444695fb91ac9bbf88f254c0fb56f7b7333313dc01e06d
```

gold/inep/

```
SHA-256 igual antes/depois:
1f2ec605ed3fd9abb73306b69577fdc952ff19aa93e866d9b97020ca5be2922e
```

auditoria/bronze/

```
SHA-256 igual antes/depois:
549c4dd47b500104bd06542bbb3a474c79f4471685f76ff95b2d32453c0124d2
```

auditoria/silver/

```
SHA-256 igual antes/depois:
e41465277e86cdefcf63d6eae96743f4c94910bafb74f9fe2bf8d316fdcfe37f
```

auditoria/gold/

```
SHA-256 igual antes/depois:
7f730dc7224810e489eba5983b9f0e366896b987d653badadc59b429cf7feb09
```

Os novos destinos ficam sob bronze/inep_streaming, silver/inep_streaming, gold/inep_streaming e auditoria/streaming. A role Lambda permite somente os caminhos incrementais necessários; o finalizador usa a identidade autenticada do ambiente para materializar seus caminhos específicos de simulação.

Passo a passo: preparar e publicar

Estes comandos documentam o procedimento de reprodução. Escolha novas pastas de evidência a cada execução e valide a conta/região. A publicação e o replay geram alterações e consumo; não os repita apenas para consultar um resultado existente.

```
cd /home/cloudshell-user/streaming_sim_v2_20261027
source .venv/bin/activate
python -m pip install -r requirements-producer.txt
python -X utf8 -m unittest discover -s . -p 'test_*.py' -v
```

1. Teste local: clientes AWS são simulados em memória; a escrita e a leitura Parquet Snappy usam a biblioteca real. A fixture histórica anonimizada serve para testes offline, sem comprovar execução AWS.

```
python aws_preflight.py --output-dir aws_before
python deploy_simulation.py --mode prepare --output-dir deployment
```

2. Conferência anterior e plano: exigir validation_status=SUCCEEDED. Revisar change_set_review.json, mantendo apenas Modify de ConsumerFunction/ConsumerRole, sem replacement, sem novos serviços e com permissões somente para os prefixos de simulação.

```
python deploy_simulation.py --mode execute --output-dir deployment
python deploy_simulation.py --mode status --output-dir deployment
```

3. Publicação: executar o plano revisado/autorizado e aguardar UPDATE_COMPLETE. O comando status consulta o estado; não dispara outro replay.

Arquivos alterados ou acrescentados

Arquivo	Função
lambda_function.py	Projeções Silver/Gold, qualidade bloqueante, recibos, recuperação e métricas até Gold.
build_stack.py / streaming_stack.json	Atualização reproduzível da função e da role existentes.
finalize_simulation.py	Compactação e manifesto imutável do snapshot validado.
verify_simulation.py / verify_negative_simulation.py	Conferência dos objetos, hashes, cálculos, Parquet e falha controlada.
aws_preflight.py / deploy_simulation.py / exercise_simulation.py	Inventário, plano restrito e um exercício de volume limitado.
capture_runtime_evidence.py / compare_official.py	Correlaciona medições operacionais e confere inventários e adições IAM autorizadas.
publish_run_evidence.py	Publica o manifesto final e as evidências; exige todas as barreiras de validação e escrita imutável.
test_*.py / events_reference.jsonl	Suíte local e fixture portátil com identificadores sintéticos.

Passo a passo: executar e comprovar

```
python exercise_simulation.py --output-dir exercise_01

python verify_simulation.py \
 --events exercise_01/producer/events.jsonl \
 --producer-report exercise_01/producer/producer_report.json \
 --output exercise_01/verification_incremental.json
```

4. Exercício limitado: 30 eventos novos, 5 reenvios idênticos e 1 evento com peso inválido em run separado. A amostra existente no S3 é carregada uma vez. Os IDs e o produtor da mesma rodada devem acompanhar todas as verificações seguintes.

```
python finalize_simulation.py \
 --events exercise_01/producer/events.jsonl \
 --output-dir exercise_01/finalized

python verify_simulation.py \
 --events exercise_01/producer/events.jsonl \
 --producer-report exercise_01/producer/producer_report.json \
 --finalization-report exercise_01/finalized/finalization_report.json \
 --output exercise_01/verification_final.json
```

5. Finalização: aguardar o caminho incremental validado. O finalizador grava os dois Parquet e publica o manifesto por último. A nova verificação deve comprovar também os bytes, as linhas e os hashes lógicos do snapshot consolidado.

```
python verify_negative_simulation.py \
 --invalid-report exercise_01/invalid_semantic.json \
 --output exercise_01/verification_negative.json

python aws_preflight.py --output-dir aws_after
```

6. Evidência negativa e preservação: aguardar as retentativas e a DLQ, executar o verificador da falha e comparar os seis inventários oficiais. INCOMPLETE exige esperar ou investigar; FAILED exige corrigir a causa. Nenhum deles pode ser apresentado como SUCCEEDED.

A mensagem de falha permanece na DLQ. Não usar purge, delete ou redrive para preparar uma evidência visual. Para corrigir uma falha real, investigar logs, preservar o envelope e os IDs, corrigir a causa e só então planejar o reprocessamento.

Passo a passo: medir e arquivar evidências

```
python compare_official.py \
 --before aws_before/preflight_report.json \
 --after aws_after/preflight_report.json \
 --output official_preservation.json

python capture_runtime_evidence.py \
 --exercise-dir exercise_01 \
 --output exercise_01/runtime_evidence.json

python publish_run_evidence.py \
 --project-dir . \
 --exercise-dir exercise_01
```

7. Medições e publicação: exigir comparação SUCCEEDED e captura COMPLETE. O publicador utiliza os JSONs da mesma rodada, incluindo deployment/source_diagnostic.json da conferência do ZIP real. Ele bloqueia fonte divergente, evidência incompleta, outra rodada ou colisão com conteúdo diferente. As escritas são imutáveis; o manifesto final é publicado após as 14 evidências.

Conferir novamente os bytes publicados

No Python do ambiente autenticado, o exemplo abaixo somente lê os objetos e compara os hashes. A saída esperada para esta entrega é SUCCEEDED 14. Não inicia consultas, jobs ou produtores.

```
import json, hashlib, boto3
from pathlib import Path
from urllib.parse import urlparse
s3 = boto3.client('s3', region_name='us-east-2')
bucket = 'fiap-tc-fase2-2026'
publication = json.loads(Path('exercise_01/audit_publication.json')
 .read_text(encoding='utf-8'))
raw = s3.get_object(Bucket=bucket, Key=publication['manifest_key'])['Body'].read()
assert hashlib.sha256(raw).hexdigest() == publication['manifest_sha256']
manifest = json.loads(raw)
assert manifest['status'] == 'SUCCEEDED'
for evidence in manifest['evidence'].values():
 location = urlparse(evidence['uri'])
 body = s3.get_object(Bucket=location.netloc,
 Key=location.path.lstrip('/'))['Body'].read()
 assert len(body) == evidence['bytes']
 assert hashlib.sha256(body).hexdigest() == evidence['sha256']
print('SUCCEEDED', len(manifest['evidence']))
```

Consultar um snapshot e operar novamente

Para estudar o resultado, selecione o manifesto exato desta rodada. Leia somente o arquivo Gold apontado por esse manifesto; listar e unir todos os diretórios snapshot_id duplicaria versões históricas. A consulta abaixo baixa os artefatos para memória local e não inicia Athena, Glue ou BigQuery.

```
Manifesto da rodada:
s3://fiap-tc-fase2-2026/auditoria/streaming/analitico/runs/run_id=sim_gold_20261027T155422Z_a52da0a7/snapshot_id=364dc24
b2ba6e750ef0103b8138a9750c9bb24e081b325234a42a509cd717c2b/manifest.json
```

```
import io, json, boto3
import pyarrow.parquet as pq
s3 = boto3.client('s3', region_name='us-east-2')
bucket = 'fiap-tc-fase2-2026'
key = (
 'auditoria/'
 'streaming/'
 'analitico/'
 'runs/'
 'run_id=sim_gold_20261027T155422Z_a52da0a7/'
 'snapshot_id=364dc24b2ba6e750ef0103b8138a9750c9bb24e081b325234a42a509cd717c2b/'
 'manifest.json'
)
manifest = json.loads(s3.get_object(
 Bucket=bucket, Key=key)['Body'].read())
assert manifest['status'] == 'SUCCEEDED'
assert manifest['simulation'] is True
gold_key = manifest['datasets']['gold']['key']
body = s3.get_object(Bucket=bucket, Key=gold_key)['Body'].read()
table = pq.read_table(io.BytesIO(body))
print(table.to_pylist())
```

Para combinar grupos de um mesmo snapshot, some numerador e denominador e só depois calcule a taxa ponderada. O exemplo usa somente boto3 e PyArrow, já fixados nas dependências do projeto.

Controles para o teto total de US$ 140

Controle	Configuração desta extensão
Lambda	256 MB; timeout 10 s; concorrência reservada 2
SQS -> Lambda	Lote máximo 5; concorrência máxima 2; falha parcial habilitada
SQS / DLQ	Visibilidade 60 s; retenção 4 dias / 14 dias; maxReceiveCount=5
Logs	Retenção configurada de 14 dias; alarmes existentes no console
Computação adicional	Sem Glue contínuo, consulta BigQuery nova ou agendamento
Armazenamento	Incrementos gzip; compactados Parquet Snappy; histórico por run/snapshot

FinOps será fechado depois desta entrega: medir logs, requisições, tempo de Lambda e armazenamento; conferir créditos/faturamento; preencher a tabela Serviço, Unidade, Quantidade medida, Preço unitário e Custo mensal projetado. Os controles acima limitam recursos, mas não substituem essa medição nem garantem um saldo de orçamento.

Evidências e pontos para apresentar ao grupo

O streaming agora chega à camada analítica de simulação. A rodada AWS comprovou chegada incremental, tratamento de duplicata, barreira de qualidade com falha real, latência medida e consolidação em Parquet. A suíte local também testou recuperação após falhas parciais e concorrência. Os dados oficiais continuam em seus próprios prefixos, com os seis inventários preservados.

Ao apresentar: mostre o run e o snapshot; explique a diferença entre o ano educacional e o horário do replay; mostre os 30 efeitos únicos apesar dos reenvios; apresente o evento de peso zero retido antes da Silver/Gold; explique o numerador e o denominador ponderados; encerre com a evidência dos inventários oficiais e com o FinOps como próxima demanda.

Documentos usados para os números

producer: producer_report.json

```
SHA-256 do arquivo:
cbd7daa0fc8fb79497ef26dd9aa7ad27faf8bfa8de4f6392b0338cc4961ce9b9
```

positive: verification_final.json

```
SHA-256 do arquivo:
3b72b13963371f0379a09591ccaae4e5229659d135adbf27bc55e862cf7032d4
```

negative: verification_negative.json

```
SHA-256 do arquivo:
e574595068d79c42901717228905776ba3e47774986a425b5f08756c0c2e30c0
```

finalization: finalization_report.json

```
SHA-256 do arquivo:
7312498908ece22dc27f022b40f00e61de645a7327965b058d30693401ac4102
```

manifest: manifest.json

```
SHA-256 do arquivo:
3ea1ad2b962623b437af2df3e711405fca06209d86d426ea9932bad8435a521f
```

exercise_metadata: exercise_metadata.json

```
SHA-256 do arquivo:
1d7185d919139512a26a394dafbf0f55b0740653c2bad660b43d73f7751f0afd
```

before: preflight_report.json

```
SHA-256 do arquivo:
128900b642bb67008afd003633bf4a9f32747e1ed611ef2931f3baf01099401a
```

after: preflight_report.json

```
SHA-256 do arquivo:
942fed6b58457780aa4712f40cbd0b37675002cb0364f0001132b5339593d26a
```

deployment: deployment_state.json

```
SHA-256 do arquivo:
5f2a2d75d10e82b807bf0355e38f21fd2fd2e6443a6bdf92c6ceb3eb0cde1a32
```

local_validation: local_validation.json

```
SHA-256 do arquivo:
e0aebcc531405a1cf09dcb83ca036861dee2fd76c116f937059154d8fa9957b0
```

runtime: runtime_evidence.json

```
SHA-256 do arquivo:
2ae878314846f85f186b9605ebcfdacab658000ae150cec2c430f6043f52f2cb
```

preservation: official_preservation.json

```
SHA-256 do arquivo:
86cc12b41bedf6ee6204f7c0bfa5b34b5ec940cf3cd63cbe6de4f43bc007e67c
```

audit_publication: audit_publication.json

```
SHA-256 do arquivo:
cdf612c388ead3c1acf960a4dd6808d157b213ab5f9f0fb712fe41e96ce50365
```

audit_readback: audit_readback.json

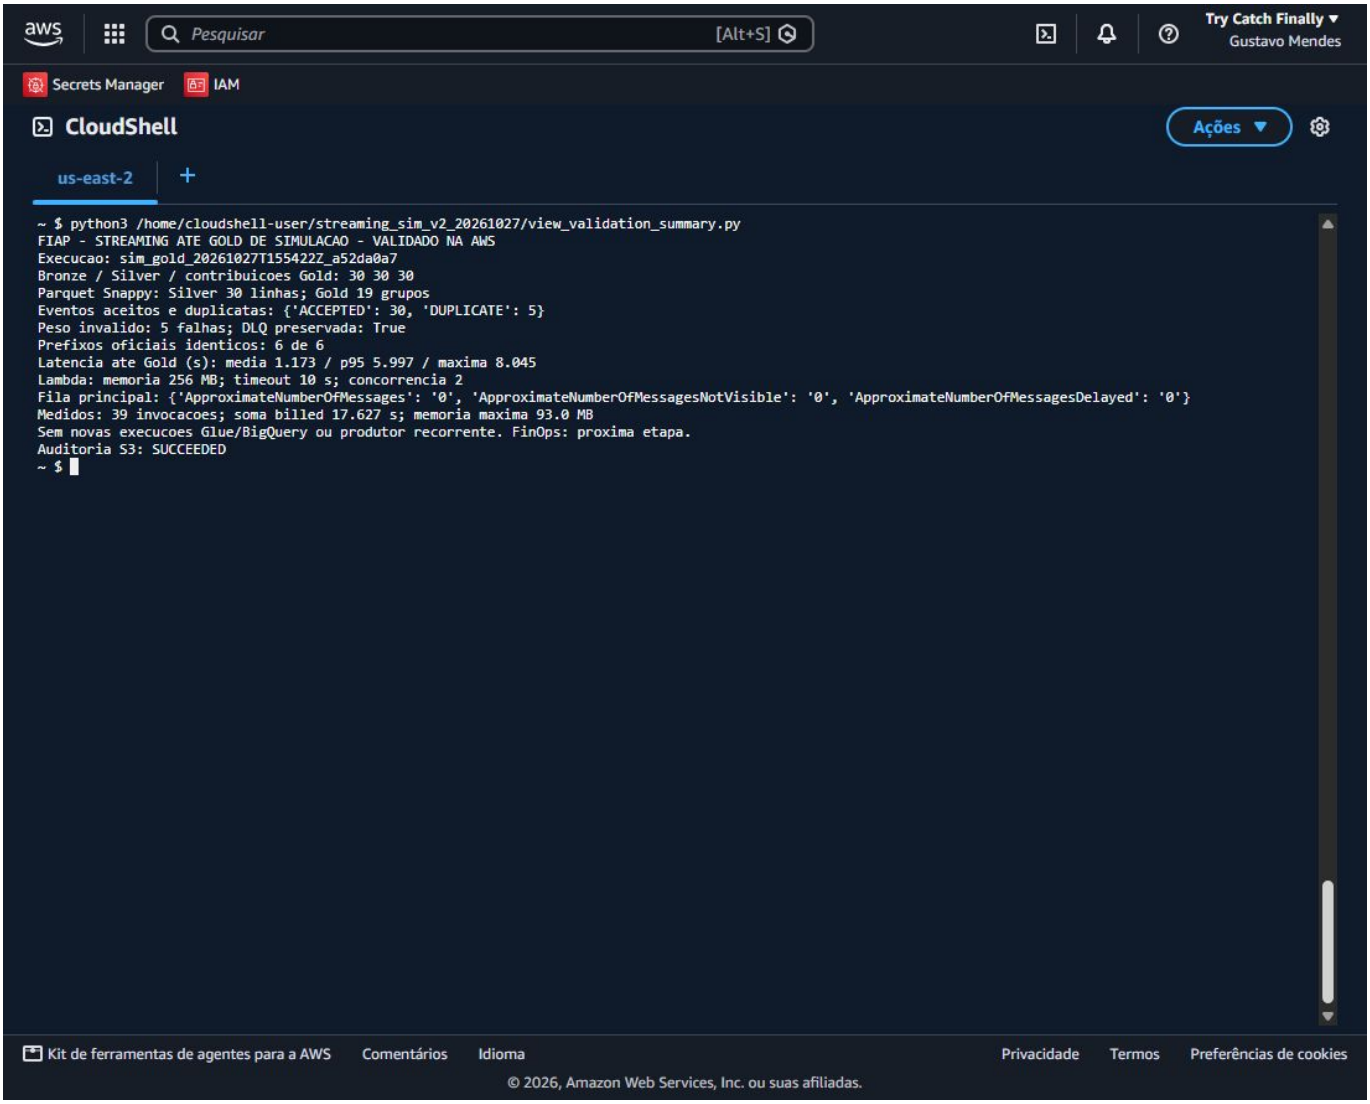
```
SHA-256 do arquivo:
7181a7289bf39d7ed0de45189ab60436a68617d2fe5697bc15d1a76b6eceb77b
```

audit_manifest: audit_manifest.json

```
SHA-256 do arquivo:
c322ff4a5271488ca19e1e55a6d4185938bc2d412d33a625244887bf433e73e4
```

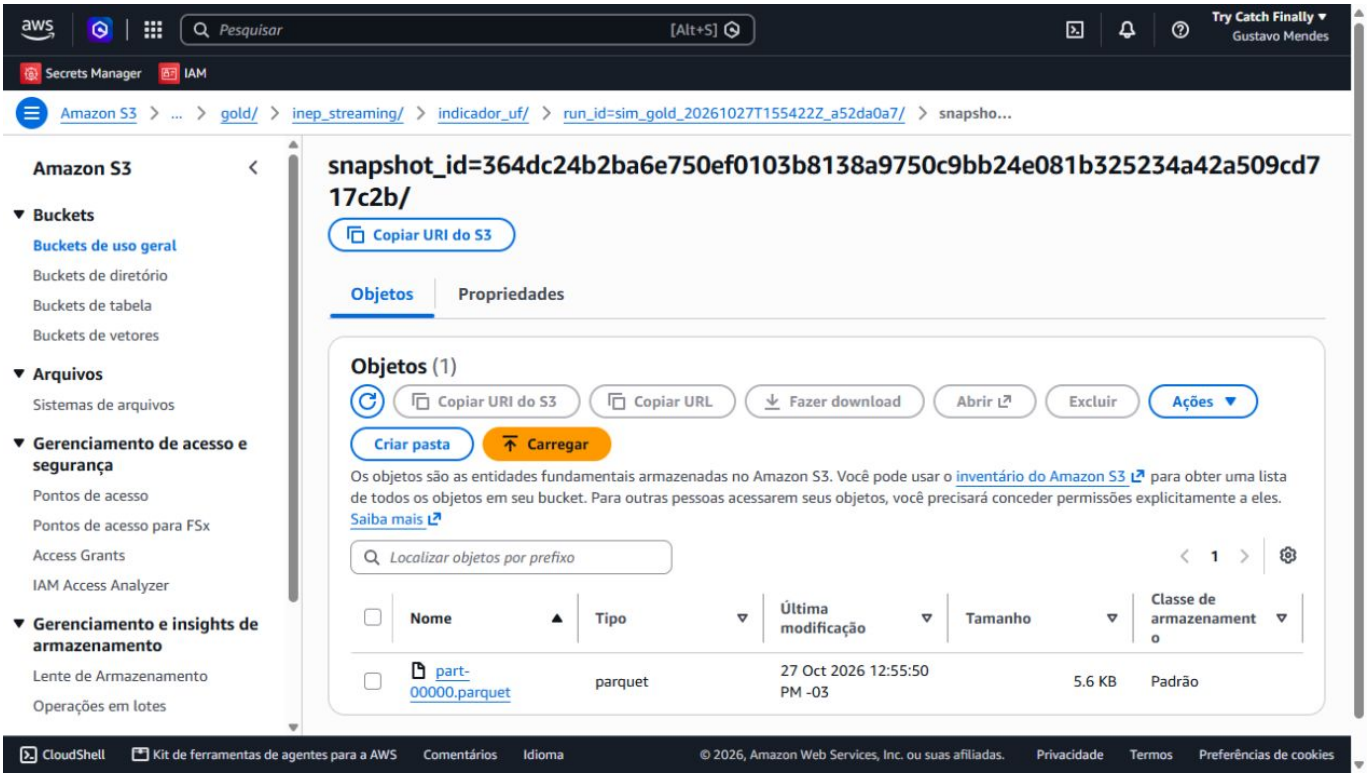
Os JSONs são a evidência primária. Este relatório foi gerado a partir deles, sem consultar a nuvem. Os estados de fila e alarmes podem mudar depois do instante da captura. A verificação da DLQ não envia e-mails, não apaga mensagens e não faz redrive.

Registro visual da verificação



CloudShell da conta do projeto em us-east-2: resumo real da validação da rodada sim_gold_20261027T155422Z_a52da0a7, incluindo contagens, latência, falha controlada e auditoria publicada. Os JSONs são a evidência primária.

Parquet Gold no console S3



Captura real do arquivo part-00000.parquet da Gold de simulação, no snapshot identificado neste relatório. A verificação final conferiu o conteúdo do arquivo, seus hashes e suas 19 linhas agrupadas.