
PDS TECH

TECH CHALLENGE

Pipeline Híbrido para Análise da Alfabetização no Brasil

O Tech Challenge é o projeto integrador desta fase e tem como objetivo consolidar os conhecimentos adquiridos nas disciplinas do curso. Trata-se de uma atividade obrigatória, preferencialmente desenvolvida em grupo, cuja pontuação corresponde a 90% da nota final. Mais do que um exercício técnico, este desafio simula um **problema real enfrentado por equipes de engenharia e ciência de dados em organizações que** trabalham com dados públicos em larga escala.

Contexto do Problema

A alfabetização na infância é um dos pilares fundamentais para o desenvolvimento educacional, social e econômico de um país. Nesse contexto, o Compromisso Nacional Criança Alfabetizada surge como uma política pública que mobiliza União, estados, Distrito Federal e municípios com o objetivo de garantir que as crianças brasileiras estejam alfabetizadas até o final do 2º ano do ensino fundamental. Para apoiar a definição de parâmetros nacionais de alfabetização, o Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira realizou, em 2023, a Pesquisa Alfabetiza Brasil. A partir desse estudo, foi definido o ponto de corte de 743 pontos na escala de proficiência do Saeb, nível a partir do qual uma criança pode ser considerada alfabetizada. Com base nesse parâmetro, foi criado o Indicador Criança Alfabetizada, que expressa o percentual de estudantes que atingem esse patamar de proficiência.

Atenção à meta de 2030

O Compromisso Nacional tem como aspiração a universalização da alfabetização até 2030. As tabelas oficiais publicadas na Base dos Dados, entretanto, trazem uma trajetória pactuada e mensurável, com valores anuais de 2024 a 2030. Para a rede Pública, a coluna meta_alfabetizacao_2030 traz o valor 80.

As duas leituras são legítimas e significam coisas diferentes. Seu projeto deve deixar isso explícito: se calcular distância até a meta, use a meta pactuada da fonte; se quiser apresentar a leitura de universalização, identifique-a como cenário

aspiracional. Não misture as duas em pontos diferentes do projeto sem dizer que trocou.

Compreender os fatores que influenciam o processo de alfabetização exige mais do que a análise isolada de indicadores educacionais. É necessário integrar diferentes fontes de dados, incluindo metas nacionais e estaduais, metas municipais, dados territoriais, microdados educacionais e indicadores de desempenho. A integração dessas fontes possibilita análises mais profundas sobre desigualdades educacionais e subsidiar políticas públicas baseadas em evidências.

Fonte de dados

Todos os dados vêm da plataforma Base dos Dados, dataset *br_inep_avaliacao_alfabetizacao*:

https://basedosdados.org/dataset/073a39d4-89cf-4068-b1e8-34ed0d9c0b72?table=e1de7a6a-5038-4e81-89f0-a15f2cc12c9b

Tabelas do dataset

Entidade	Tabela oficial	Conteúdo
Dados de alunos	alunos	microdado individual: proficiência, presença, preenchimento de caderno, alfabetizado, peso amostral
Município	municipio	indicador por município, ano, série e rede
UF	uf	indicador por UF, ano, série e rede
Meta Alfabetização Brasil	meta_alfabetizacao_brasil	trajetória nacional 2024 a 2030
Meta Alfabetização por UF	meta_alfabetizacao_uf	trajetória estadual
Meta Alfabetização por Município	meta_alfabetizacao_municipio	trajetória municipal
Dicionário	dicionario	tradução oficial dos códigos de rede, série, presença e demais colunas categóricas

A tabela dicionário existe justamente para você não precisar inventar a correspondência entre código e descrição. Use-a.

Forma de acesso

A plataforma oferece as tabelas nativamente no BigQuery e também permite o download direto dos arquivos. As duas formas são aceitas e não há desconto de pontos por nenhuma delas. O que se avalia é se a escolha foi consciente e justificada no README, considerando arquitetura, custo e atualização da fonte. Registre no README:

- ✓ Por que você escolheu esse caminho;
- ✓ O que isso implica em custo (bytes escaneados, transferência entre nuvens, egress);
- ✓ O que acontece quando a fonte for atualizada.

O DESAFIO

Sua equipe atuará como um time de engenharia de dados de uma organização pública de análise educacional. O objetivo é construir uma pipeline híbrida de dados (Batch + Streaming) capaz de integrar diferentes fontes relacionadas ao indicador de alfabetização, garantindo qualidade, escalabilidade e eficiência de custos em ambiente de nuvem.

A pipeline deverá seguir a **Arquitetura Medalhão**, com **camadas Bronze (dados brutos), Silver (dados tratados) e Gold (dados analíticos)**, considerando práticas modernas de engenharia de dados: ingestão híbrida, monitoramento de pipelines, governança e qualidade de dados e otimização de custos em nuvem (FinOps).

Objetivo técnico

Construir uma pipeline de dados escalável em nuvem que realize:

- ✓ Ingestão de diferentes fontes de dados educacionais;
- ✓ Tratamento e padronização das informações;
- ✓ Integração entre bases heterogêneas;
- ✓ Disponibilização de uma camada analítica confiável;
- ✓ Monitoramento operacional do pipeline;

- ✓ Controle de custos da infraestrutura.

Entidades a integrar

UF, Meta Alfabetização Brasil, Meta Alfabetização por UF, Meta Alfabetização por Município, Município e Dados de alunos. Todas as seis entidades devem ser efetivamente utilizadas ao longo da pipeline. Ingerir uma tabela, tratá-la e nunca usá-la é custo de armazenamento e de processamento sem retorno analítico, e será avaliado como tal.

Arquitetura Esperada

Ingestão Batch

Processamento periódico para ingestão dos dados históricos: metas educacionais, dados de municípios e UFs, microdados de alunos e agregados nacionais.

Ingestão Streaming

Simulação de ingestão de eventos em tempo quase real, como atualização de indicadores, novas medições de desempenho ou atualização de metas e resultados.

O que se avalia aqui: que você compreenda e aplique o modelo de streaming, e que demonstre entender em que ele difere do batch. Simular o fluxo de eventos e levar o evento até a camada analítica final têm o mesmo peso na avaliação. O que precisa ficar claro é:

- ✓ O mecanismo de mensageria ou de recepção de eventos, mesmo que simulado;
- ✓ O processamento incremental, em micro-lotes ou contínuo;
- ✓ A diferença de latência, de frequência e de garantias em relação ao batch, explicada no readme;
- ✓ O tratamento de evento inválido ou duplicado, já que mensageria costuma entregar pelo menos uma vez.

Um cuidado importante: se o dado simulado se juntar ao dado oficial em qualquer camada, mantenha uma coluna que identifique a origem. Número gerado por

simulador não deve se misturar ao indicador oficial sem que ninguém consiga separá-los depois.

Arquitetura Medalhão

Bronze Layer, Raw Data

- ✓ Dados brutos ingeridos das fontes;
- ✓ Armazenamento sem transformações significativas;
- ✓ Histórico completo preservado.

Preservar histórico significa que uma execução não apaga a anterior. Atenção: criar uma partição por data de ingestão e depois sobrescrever o caminho inteiro a cada execução não preserva histórico. Verifique o comportamento real do seu modo de escrita (overwrite, WRITE_TRUNCATE, CREATE OR REPLACE, sobrescrita dinâmica de partição) e descreva no README a política adotada.

Silver Layer, Dados Tratados

- ✓ Limpeza de dados;
- ✓ Tratamento de valores ausentes;
- ✓ Padronização de nomes e tipos;
- ✓ Validação de consistência;
- ✓ Normalização de chaves;
- ✓ Integração das bases.

Gold Layer, Camada Analítica

Datasets prontos para análise, por exemplo:

- ✓ Indicador de alfabetização por município;
- ✓ Comparação entre metas e resultados;
- ✓ Evolução temporal do indicador.

Preparada para dashboards, análises estatísticas e treinamento de modelos de machine learning.

Importante você guardar o dataset da camada analítica para ser utilizado na próxima fase 3 para treinamento de um modelo preditivo.

Regras de Qualidade de Dados

A pipeline deve incluir mecanismos de validação:

- ✓ Verificação de duplicidade;
- ✓ Detecção de valores ausentes;
- ✓ Validação de chaves de relacionamento;
- ✓ Consistência entre tabelas;
- ✓ Taxa de correspondência dos joins.

Uma regra de qualidade só cumpre sua função se impedir que dado ruim avance. Seu projeto deve:

- ✓ Classificar as regras entre bloqueantes e informativas;
- ✓ Interromper a execução quando uma regra bloqueante falhar, antes de a camada seguinte ser publicada;
- ✓ Registrar o resultado das validações em algum lugar que sobreviva ao fim da execução.

Cuidado com o padrão em que a exceção é levantada corretamente e depois capturada por um except genérico que apenas registra a falha e deixa o processo terminar com sucesso.

Demonstre o pipeline falhando. Um relatório de qualidade que só mostra aprovação não prova o funcionamento.

Sobre a taxa de correspondência de joins

Esta validação é obrigatória.

Um join que não encontra correspondência não gera erro: ele devolve nulo, e o nulo se propaga por toda a camada analítica até virar um indicador errado.

Depois de cada junção entre tabelas, meça quantas linhas encontraram par e reprove quando ficar abaixo de um limiar que você definir e justificar.

Monitoramento da Pipeline

Monitoramentos esperados:

- ✓ Falhas de ingestão;
- ✓ Latência do pipeline;
- ✓ Volume de dados processados;
- ✓ Alertas de erro.

Logging não é observabilidade

Mensagem impressa no terminal desaparece quando a sessão fecha. Para o critério ser atendido:

- ✓ As métricas de execução (duração por etapa, linhas de entrada e saída, status) precisam ser persistidas, acumulando execuções em vez de sobrescrever;
- ✓ Deve existir alguma forma de notificação quando o pipeline falhar, seja política de alerta na nuvem, e-mail, webhook ou equivalente;
- ✓ A latência precisa ser medida de fato.

Sobre medir latência no streaming: a latência é a diferença entre o momento em que o evento foi produzido e o momento em que ele foi ingerido. Se o produtor gravar o mesmo carimbo de tempo nos dois campos, a diferença será sempre zero e a métrica não medirá nada.

O README deve responder: em produção, quem descobre que o pipeline quebrou, e em quanto tempo?

FinOps, Otimização de Custos

Práticas esperadas:

- ✓ Uso eficiente de armazenamento (Parquet, compressão, particionamento);
- ✓ Otimização de queries (seleção de colunas, filtro na origem, evitar leitura repetida);
- ✓ Controle de recursos computacionais;
- ✓ Estimativa de custo da arquitetura.

A estimativa precisa ter números medidos.

Listar boas práticas não é estimar custo. Apresente uma tabela com:

Serviço	Unidade	Quantidade medida	Preço unitário	Custo mensal projetado

Use as ferramentas de medição da sua nuvem para obter as quantidades reais (dry run no BigQuery, dados escaneados no Athena, duração de job, tamanho dos objetos no storage). Estimativa ancorada em medição vale muito mais do que premissa inventada, e premissa inflada para cima não é conservadorismo, é imprecisão. Se o ambiente usado for gratuito ou sandbox, informe isso e projete o custo do mesmo desenho em produção, com a cadência de execução pretendida.

Se usar mais de uma nuvem

Multi cloud é uma decisão e não haverá desconto por ela. Mas ela precisa estar justificada, e o README deve discutir o que ela cobra: transferência de saída de dados, duplicação de armazenamento, duas contas de billing para conciliar, dois modelos de identidade e acesso para governar e um time que precisa dominar dois ecossistemas.

Implementação em Cloud

A solução deve ser implementada e executada em ambiente de nuvem: AWS, GCP ou Azure. Implementada significa executada de verdade, com evidência. Script que valida um plano sem materializar recursos, ou infraestrutura declarada e nunca provisionada, não caracterizam implementação. Inclua evidências de execução: identificadores de job, prints de console, logs, contagens de linhas nas tabelas criadas.

Reprodutibilidade

Um avaliador deve conseguir clonar o repositório e executar a pipeline seguindo apenas o README.

Antes de entregar, faça o teste em um clone limpo:

- ✓ Os caminhos citados no README existem e estão escritos exatamente como no código;
- ✓ Os arquivos de código têm a extensão correta;

- ✓ As dependências estão declaradas com versão;
- ✓ Identificadores de projeto, bucket e credencial são configuráveis (variável de ambiente ou arquivo de configuração), não fixos em vários arquivos;
- ✓ Nenhuma credencial está versionada;
- ✓ Os testes, se existirem, passam.

Formato da Entrega

Seu README deve conter:

- Contexto do problema. Explicação do desafio educacional e do uso do indicador de alfabetização.
- Arquitetura proposta. Descrição da arquitetura da solução, com diagrama da pipeline e fluxo de dados. O diagrama deve refletir o que foi implementado, não o que se pretendia implementar.
- Tecnologias utilizadas. Ferramentas escolhidas e justificativa. Distinga claramente o que está implementado do que é evolução futura.
- Decisões arquiteturais. Trade-offs como batch versus streaming, data lake versus data warehouse, custo versus performance, forma de acesso à fonte.
- Monitoramento e FinOps. Como o pipeline é monitorado e como os custos são controlados, com a tabela de estimativa.
- Aplicação em IA. Como a base Gold poderia ser usada para modelos de predição de alfabetização, análise de desigualdade educacional e políticas públicas baseadas em dados. Se construir uma base de features, atenção ao vazamento de alvo: entregar na mesma tabela a variável alvo e uma coluna derivada dela produz um modelo que acerta tudo sem ter aprendido nada.
- Limitações conhecidas. O que ficou de fora, o que foi simulado, quais lacunas da fonte permaneceram. Assumir limitação vale mais do que escondê-la.
- Link do vídeo executivo.

Documentação precisa descrever o projeto

Descrever no README um processo que não existe no repositório (CI que não está configurado, alertas que não foram criados, fluxo de branches que o histórico não

mostra) custa credibilidade e será apontado na avaliação. Prefira escrever "planejado para a próxima etapa" a escrever no presente algo que ainda não aconteceu.

Estrutura mínima do repositório

- ✓ Código-fonte dos pipelines;
- ✓ Estrutura clara das camadas bronze, silver e gold;
- ✓ Scripts de validação e qualidade de dados;
- ✓ Documentação técnica;
- ✓ Readme completo explicando a solução;
- ✓ Evidências de execução.

Vídeo Executivo (até 5 minutos)

O grupo deverá gravar um vídeo de até 5 minutos, no qual pelo menos um integrante apresenta o projeto em linguagem executiva, simulando uma apresentação para liderança ou stakeholders. O vídeo deve abordar problema de negócio, arquitetura da solução, valor da pipeline para análises educacionais e potencial uso para inteligência artificial. O link do vídeo deve estar no README.

Se apresentar gráficos, rotule os eixos e garanta que os números citados na narração sejam os mesmos do repositório. Número que o público não consegue rastrear no gráfico vira ruído, e divergência entre slide e código levanta dúvida sobre o restante.

Erros comuns em pipelines de dados públicos

- Esta seção não entrega soluções, apenas alerta para armadilhas que não quebram o pipeline e por isso passam despercebidas.
- Join que não casa não gera erro, gera nulo. Sempre meça a taxa de correspondência depois de cada junção.
- Verifique se as chaves falam a mesma língua. Colunas categóricas podem ter representações diferentes entre tabelas do mesmo dataset. Compare os valores dos dois lados antes de assumir que a junção funcionou, e confira também os tipos.
- Preencher nulo com zero transforma "não sei" em "é zero". Em uma escala de proficiência, zero é um valor impossível que distorce qualquer média. Em

uma meta, zero faz todo mundo atingi-la. Prefira preservar o nulo e filtrar quando necessário.

- Ausência de meta e falha em atingir a meta são estados diferentes. Uma comparação com nulo é falsa, e o else costuma classificar como "não atingiu" quem simplesmente não tem meta cadastrada. Use um terceiro estado.
- Média simples entre municípios não é o indicador nacional. O indicador publicado é ponderado por alunos. Agregar municípios com peso igual faz uma cidade pequena pesar o mesmo que uma capital, e o resultado não bate com o número oficial. Se optar pela média simples, nomeie a coluna de acordo.
- Cuidado com o universo de rede e de série. Compare resultado com meta apenas quando os dois se referirem ao mesmo recorte. Comparar o resultado de uma rede com a meta de outra produz um número que parece correto e não é.
- Confira o denominador. A taxa de alfabetização se calcula sobre os alunos avaliados, com o peso amostral, e não sobre o total de registros da base. Incluir ausentes no denominador puxa a taxa para baixo de forma sistemática.
- Fallback apaga informação. Um else que classifica todo código desconhecido como uma categoria válida faz um valor novo da fonte entrar errado sem que nada acuse. Prefira uma categoria explícita de "desconhecido" com um check que exija contagem zero.
- Extrapolação com poucos pontos é frágil. Com dois ou três anos de série, projetar até 2030 é um cenário, não uma previsão. Apresente como tal.

📊Critérios de avaliação

Critério	Pontos
Ingestão híbrida (batch + streaming)	15
Arquitetura Medalhão	15
Qualidade de dados	10
Monitoramento e observabilidade	10

Critério	Pontos
FinOps	10
Cloud e organização do repositório	10
README e documentação	5
Vídeo executivo	15
Total	**90**

Diferenciais valorizados

Não são obrigatórios, mas elevam a entrega:

- Validação cruzada entre microdado e indicador oficial. Recalcular a taxa de alfabetização a partir dos microdados de alunos, ponderando pelo peso amostral e usando como denominador os alunos avaliados, e confrontar o resultado com a taxa publicada. Se os dois números convergem, todas as etapas anteriores da sua pipeline estão corretas por consequência. É a evidência mais forte que este dataset permite produzir.
- Orquestração. Encadear as etapas com dependência, retentativa e agendamento, em vez de comandos executados manualmente em sequência.
- Infraestrutura como código. Ambiente recriável por um comando, com estado e diff revisável.
- Testes automatizados sobre as funções de transformação.
- Investigação documentada. Encontrar uma anomalia no dado, apurar a causa e registrar a conclusão vale mais do que uma entrega sem nenhuma anomalia aparente. Dado público real tem lacunas, e mostrar que você as enfrentou é exatamente o que se espera de um engenheiro de dados.

Boa sorte no desenvolvimento do projeto! E não deixem de discutir suas ideias com os professores e professoras ao longo do processo!


POS TECH